تقرير تنظيف وتحسين بيانات فاقد الغذاء

مراجعة نتائج Step 1 وStep 2 والملف النهائي

إعداد وتحليل البيانات

7 نوفمبر 2026

هذا التقرير يوثّق المشكلات التي اكتشفها Step 1، والإجراءات المنفذة في Step 2، وحالة الملف النهائي بعد التنظيف.

المحتويات

1 الملخص التنفيذي 1

2 نطاق المراجعة والمنهج 1

3 نتائج الأعمدة بالتفصيل 1

3.1 1. الأكواد والأسماء الجغرافية 1

3.1.1 m49_code 1

3.1.2 country 1

3.1.3 region 2

3.2 2. الأكواد والمنتجات 2

3.2.1 cpc_code 2

3.2.2 commodity 2

3.3 3. السنوات والمؤشرات الرقمية 2

3.3.1 year 2

3.3.2 loss_percentage 2

3.3.3 loss_percentage_original 2

3.3.4 loss_quantity 2

3.4 4. النشاط ومرحلة سلسلة الإمداد 2

3.4.1 activity 2

3.4.2 food_supply_stage 3

3.5 5. الحقول النصية شديدة النقص 3

3.5.1 treatment وcause_of_loss 3

3.5.2 sample_size وnotes 3

3.6 6. مصادر التوثيق والروابط 3

3.6.1 method_data_collection 3

3.6.2 reference 3

3.6.3 url 3

4 الملف النهائي 3

5 الأعمدة الجديدة في الملف النهائي 4

6 نقاط المتابعة والتوصيات 4

1 الملخص التنفيذي

تبدأ العملية ببيانات خام تضم 31,465 صفاً و18 عموداً. كشف الفحص الأولي عن مشكلات في التكرار، واتساق أسماء الدول والمنتجات، والقيم الناقصة، وتعدد الأنشطة داخل الصف الواحد، إضافة إلى حقول نصية غير مناسبة للتحليل المباشر.
عالج Step 2 المشكلات القابلة للتنظيف دون تغيير القيم الأصلية الحساسة. حُذفت الحقول شديدة النقص أو غير القابلة للاستخدام التحليلي، ووُحّدت الأكواد والأسماء، وأعيد تنظيم activity دون تفجير الصفوف. نتج عن ذلك ملف نهائي يضم 31,164 صفاً و142 دولة و15 عموداً.

31,465	31,164	4.65%
صفاً في الخام	صفاً في النهائي	متوسط الفقد

الخلاصة العملية: الملف النهائي صالح للتحليل على مستوى القياس الواحد، مع بقاء عدد محدود من نقاط المتابعة الموثقة في نهاية التقرير.

2 نطاق المراجعة والمنهج

تمت مراجعة كل عمود من الأعمدة الثمانية عشر على ثلاث مراحل: ما اكتشفه Step 1، وما نُفذ في Step 2، ثم الحالة في الملف النهائي. أُعطيَت الأولوية للحفاظ على المعنى الأصلي للبيانات، وتجنب تضخيم عدد الصفوف، والفصل بين التنظيف المؤكد والحالات التي تحتاج مراجعة تحليلية لاحقة.

3 نتائج الأعمدة بالتفصيل

3.1 1. الأكواد والأسماء الجغرافية

3.1.1 `m49_code`

- اكتشف Step 1 وجود 157 كوداً بلا قيم ناقصة.
- ظهر اسمان للكود 158 (تايوان) وللكود 826 (بريطانيا)، دون وجود دولة واحدة بأكثر من كود.
- في Step 2 أصبح الاسم يُحدد من الكود عبر `country_name_mapping`، وأزيلت المناطق المجمعة اعتماداً على الكود.
- **في النهائي:** أكواد دول فقط.

3.1.2 `country`

- وُجد 159 زوجاً من الاسم والكود: 137 دولة، و14 منطقة، و8 حالات غير مصنفة.
- احتوى العمود على 14 اسماً جغرافياً مجمعاً مثل World وAfrica وAsia، إلى جانب أسماء غير مطابقة لتسمية الأمم المتحدة.
- وُحّدت الأسماء بالـ mapping، وأزيلت إسرائيل، ثم فُلترت البيانات إلى `Country / Area`.
- **تصحيح مهم:** كان الدمج بالاسم والكود يُسقط قرابة 4,000 صف لدول حقيقية؛ صُحح ذلك بالدمج على الكود فقط.
- **في النهائي:** 142 دولة.

`region` 3.1.3

كان 93.5% من العمود ناقصاً، مع 377 اسماً غير موجود في تصنيف الأمم المتحدة، ومسافات وتهجئات مختلفة، وأسماء مشتركة بين دول، ومستويات جغرافية مختلطة مثل National average وأسماء المدن. لذلك حُذف العمود، وهو غير موجود في النهائي.

3.2 2. الأكواد والمنتجات

`cpc_code` 3.2.1

- لا توجد قيم ناقصة أو مسافات زائدة، لكن 30,719 صفاً تبدأ أكوادها بصفر، بما يخلق خطراً عند قراءتها كأرقام.
- وُجد كودان يحتويان حروفاً: `21116i` و`2351f`، و15 كوداً غير موجودة في مرجع CPC.
- كان 17 كوداً مرتبطاً بأكثر من اسم منتج. حُوّل العمود إلى نص، واختير اسم موحد من القاموس، مع إبقاء الأكواد غير المألوفة لأنها موجودة فعلياً.
- **في النهائي:** 196 كوداً، لكل كود اسم واحد بالضبط.

`commodity` 3.2.2

وُجد 213 اسماً، منها اختلافات في حالة الأحرف، و15 كلمة مشكوك في إملائها، وأسماء مقطوعة، ووسوم HTML داخل النص. وُحّدت الأسماء وصُححت التهجئة مع استثناء الكلمات العلمية الصحيحة.

> **ملاحظة متبقية:** لا يزال 116 صفاً يحتوي وسوم `<i>...</i>` في اسم المنتج، خصوصاً Chillies and peppers, dry وPepper.

3.3 3. السنوات والمؤشرات الرقمية

`year` 3.3.1

لا توجد مشكلة: لا قيم ناقصة أو غير رقمية، والمدى من 2000 إلى 2026. لم يُجرَ أي تغيير؛ من بينها 10 صفوف في عامي 2025 و2026.

`loss_percentage` 3.3.2

- لا توجد قيم ناقصة أو خارج النطاق 0–100.
- ظهر 3,555 قيمة متطرفة وفق IQR، و3,191 قيمة بين 0 و1، لكنها لم تُغيّر لأنها مطابقة للأصل.
- تطابقت مع `loss_percentage_original` في 22,025 صفاً قابلاً للمقارنة، دون فرق أو فرق بمعامل 100.
- تسبب explode سابقاً في تكرار القيمة ورفع المتوسط إلى 6.10%؛ بعد التصحيح أصبح المتوسط 4.65%.

`loss_percentage_original` 3.3.3

احتوى 9,025 صفاً على علامة %، و9,440 قيمة غير رقمية صافية، منها نطاقات مثل 0–3%. حُذف العمود لتكراره في المعنى، وأُضيف `loss_is_range` للحفاظ على معلومة النطاق في 742 صفاً؛ وتُخزن النطاقات كمنتصف المدى، مثل 1–2% ← 1.5%.

`loss_quantity` 3.3.4

كان 84% من العمود ناقصاً، مع 691 قيمة نصية بوحدات مختلفة و601 قيمة متطرفة. لذلك حُذف من الملف النهائي.

3.4 4. النشاط ومرحلة سلسلة الإمداد

`activity` 3.4.1

- 7,370 قيمة ناقصة، و180 قيمة مختلفة بسبب تعدد الأنشطة في الخانة الواحدة.

- 5,939 من القيم الناقصة كانت Whole supply chain.
- النسخة القديمة من Step 2 استخدمت explode، ما ضخّم البيانات، ثم عوضت القيم بنموذج ضعيف (F1 ≈ 0.22).
- النسخة الجديدة رتبت الأنشطة أبجدياً داخل النص، وعوضت الناقص من `food_supply_stage` أو وضعت Unknown.
- **في النهائي:** لا توجد قيم ناقصة، مع 719 صفاً بقيمة Unknown.

`food_supply_stage` 3.4.2

كان 10.8% ناقصاً، مع 20 مرحلة بلا تشابه كتابي و6,147 صفاً بمرحلة واسعة هي Whole supply chain. استُخدم لتعويض activity ثم حُذف من النهائي.

3.5 5. الحقول النصية شديدة النقص

`cause_of_loss` و`treatment` 3.5.1

بلغ النقص 94.3% في treatment و96.5% في cause_of_loss. كما تضمنت القيم جملاً طويلة، واحتوت 453 خانة على أكثر من سبب، بطول يصل إلى 2,594 حرفاً. حُذف العمودان.

`sample_size` و`notes` 3.5.2

كان sample_size ناقصاً في 94.1% من الصفوف، مع 1,206 قيمة غير رقمية. أما notes فكان ناقصاً بنحو 95%. حُذفا لضعف القيمة التحليلية في صورتهما الحالية.

3.6 6. مصادر التوثيق والروابط

`method_data_collection` 3.6.1

وُجدت 36 قيمة ناقصة و11 طريقة جمع دون اختلافات كتابية. كانت Modelled Estimates الأكثر تكراراً (19,497 صفاً). لم يُغيّر العمود؛ ويمكن اختيارياً تعويض الناقص بـ Not specified.

`reference` 3.6.2

يحتوي العمود على 73 قيمة ناقصة، ولم يُجرَ عليه تغيير.

`url` 3.6.3

كان ناقصاً في 9,342 صفاً (29.7%)، ثم أصبح النقص 9,203 في النهائي. لا يؤثر ذلك على التحليل الأساسي.

4 الملف النهائي

الملف الناتج هو `World-food-waste_cleaned_final.csv`، ويحتوي على 31,164 صفاً و142 دولة و15 عموداً.

المؤشر, القيمة	
إزالة التكرار, 180 صفاً مكرراً تماماً؛ 31,285 بعد الإزالة	
التصفية الجغرافية, إزالة المناطق وإسرائيل؛ 31,164 في النهائي	
متوسط الفقد, 4.65%	
وحدة التحليل, صف واحد لكل قياس	

5 الأعمدة الجديدة في الملف النهائي

العمود, المعنى, الاستخدام	loss_is_range, [True إذا كانت النسبة الأصلية مدى؛ 742 صفاً], [استخدم False للقياسات الدقيقة فقط]	activity_count, [عدد الأنشطة؛ 0 يعني Unknown، و1 يعني نشاطاً واحداً], [استخدم == 1 لتحليل مرحلة واحدة]
activity_source, [Original: 23,994؛ Filled: 6,451، Unknown: 719], [استخدم Original لأكثر نتيجة نظافة]	record_id, [رقم من 1 إلى 31,164], [يربط الملف بملف long؛ يمكن حذفه عند عدم الحاجة]	record_type, [كل القيم Country / Area], [لا فائدة تحليلية؛ يُنصح بحذفه]

6 نقاط المتابعة والتوصيات

1. إزالة وسوم HTML من 116 صفاً عبر commodity.str.replace(r"</?i>", "", regex=True).
2. توثيق سبب استبعاد إسرائيل (14 صفاً) بوضوح في وصف المنهج.
3. تحديد سياسة التعامل مع 719 صفاً ذات activity = Unknown قبل أي تحليل مرحلي.
4. توحيد أسماء الدول بين الصيغة الرسمية والمختصرة، مثل Russian Federation وUSA.
5. تعويض القيم الناقصة في method_data_collection بـ Not specified فقط إذا كان ذلك مناسباً لغرض التحليل.
6. حذف record_type، وحذف record_id فقط إذا لم تعد هناك حاجة للربط مع ملف long.

الحكم النهائي: النسخة الحالية تمثل أساساً تحليلياً نظيفاً ومتسقاً بدرجة جيدة. الملاحظات المتبقية محدودة، موثقة، ولا تمنع الاستخدام التحليلي بعد تطبيق قرارات المتابعة المناسبة.