تقرير مراجعة وتحليل جودة البيانات

Food Loss and Waste Dataset — Step 1

شرح تفصيلي بالمصري لنتائج الاستكشاف والفحص، والمشاكل اللي محتاجة مراجعة، وخطة التعامل معاها من غير ما نغيّر المصدر الأصلي بالتخمين.

البند	التفاصيل
ملف التحليل	Step_1_Data_Exploration_And_Column_Profiling_FINAL(1).ipynb
ملف الداتا الظاهر في مخرجات الـ Notebook	World-food-waste.csv
حجم الداتا وقت التشغيل المسجل	31,465 صف × 18 عمود
نطاق التقرير	كل أقسام التحليل والنتائج المحفوظة داخل الـ Notebook المرفوع
تاريخ إعداد التقرير	2026-10-20

ملاحظة مهمة: التقرير مبني على الـ outputs المحفوظة داخل نسخة الـ Notebook المرفوعة. ده معناه إنه بيوثّق نتيجة التشغيل الظاهرة في الملف، مش تأكيد إن كل الخلايا اتشغّلت من جديد دلوقتي أو إن كل الروابط الخارجية ما زالت متاحة.

1. الملخص التنفيذي

الـ Notebook بيحلّل قاعدة بيانات فاقد وهدر الغذاء، وبيحاول يكتشف مشاكل الجودة قبل ما نستخدم الداتا في التحليل أو بناء موديل. التحليل هنا مش معناه إن كل قيمة مختلفة غلط؛ هو بيطلع إشارات للمراجعة، وبعدها القرار يكون بالرجوع للمصدر وقواعد المجال.

النتيجة الأساسية: عندنا 31,465 سجل و18 عمود. كل صف فيه على الأقل قيمة ناقصة واحدة، ومفيش صف واحد كامل من غير أي missing value. ده مش معناه إن كل الصفوف غير صالحة؛ لأن أعمدة زي السبب والعلاج وحجم العينة ممكن تكون اختيارية حسب نوع الدراسة، لكن لازم نفهم النقص ونوثّقه.

- أهم مشكلة في التكرار: 180 صفًا تظهر كتكرارات إضافية حسب duplicated()، وإجمالي الصفوف المنتمية لمجموعات تطابق كاملًا عند احتساب كل النسخ = 339.
- أهم مشكلة جغرافية: 282 سجلًا في تقرير مشاكل زوج الدولة والكود، و666 سجلًا يحتاج مراجعة مستوى المنطقة الجغرافية. بعض الحالات متوقعة لأن البيانات تشمل World ومناطق إقليمية وأسماء دول تاريخية/بديلة.
- أكبر مشكلة في النقص: cause_of_loss ناقص في 96.51%، notes في 95.12%، treatment في 94.32%، sample_size في 94.08%، region في 93.53%، وloss_quantity في 83.95%.
- أكبر مشكلة في تنسيق الأرقام: loss_quantity فيه 691 قيمة مش رقمية مباشرة بسبب وحدات أو نصوص، وsample_size فيه 1,206 قيمة غير رقمية. لازم نفهم المعنى والوحدة قبل التحويل.
- عمود loss_percentage نفسه مفيهوش missing ولا قيم خارج 0–100، لكن 3,555 قيمة اتعلّمت كـ statistical outliers بطريقة IQR، وده محتاج مراجعة مش حذف تلقائي.

إزاي تقري التقرير؟

كل نتيجة تحتها: (1) اللي الاختبار قاسه، (2) النتيجة المسجلة، (3) معناها المحتمل، (4) الإجراء المقترح. الأعداد هي نتائج الملف وقت حفظ الـ outputs، فلو شغّلتي نسخة مختلفة من الداتا ممكن الأعداد تتغير.

2. وصف الداتا وبنية الأعمدة

الملف المسجّل في المخرجات: World-food-waste.csv، وعدد السجلات 31,465، وعدد الأعمدة 18، واستهلاك الذاكرة المعلن في ملخص الـ Notebook حوالي 25.66 MB. الـ info الظاهر بيعرض 4.3 MB تقريبًا كحجم أعمدة البيانات نفسها؛ الفرق ممكن يرجع لطريقة حساب الذاكرة.

العمود	المعنى العملي	النوع الظاهر	القيم الناقصة
m49_code	كود الدولة/المنطقة في M49	int64	0
country	اسم الدولة أو الكيان الجغرافي	نصي	0
region	منطقة محلية/دراسة داخل البلد	نصي	29,429 (93.53%)
cpc_code	كود تصنيف السلعة CPC	نصي	0
commodity	اسم السلعة الغذائية	نصي	0
year	سنة البيانات	int64	0
loss_percentage	نسبة الفاقد	float64	0
loss_percentage_original	القيمة النصية الأصلية للنسبة	نصي	0
loss_quantity	كمية الفاقد، قد تحتوي وحدة مكتوبة	نصي	26,415 (83.95%)

activity	النشاط أو العملية	نصي	7,370 (23.42%)
food_supply_stage	مرحلة سلسلة الإمداد	نصي	3,391 (10.78%)
treatment	معاملة/طريقة التعامل المذكورة بالدراسة	نصي	29,678 (94.32%)
cause_of_loss	سبب الفاقد	نصي	30,367 (96.51%)
sample_size	حجم العينة	نصي	29,603 (94.08%)
method_data_collection	طريقة جمع/تقدير البيانات	نصي	36 (0.11%)
reference	مرجع الدراسة	نصي	73 (0.23%)
url	رابط المصدر	نصي	9,342 (29.69%)
notes	ملاحظات إضافية	نصي	29,931 (95.12%)

ملحوظة: الأعمدة النصية مش بالضرورة نصوص عادية. بعض الأعمدة زي loss_quantity وsample_size مخزّنة كنص لأن فيها وحدات أو وصفًا أو قيمًا غير رقمية. لازم نعمل عمودًا رقميًا مشتقًا بعد التنظيف، ونحتفظ بالأصل.

3. فحص القيم الناقصة Missing Values

الـ Notebook فحص القيم الناقصة الفعلية، وكمان رموز النص اللي ممكن تمثل missing زي NA وN/A وNULL وNONE وUNKNOWN وMISSING والشرطة. في مخرجات الفحص، معظم النقص ظاهر كـ NaN حقيقي، ومفيش empty strings مسجلة في تقرير missing-token للأعمدة المعروضة. عمود sample_size فيه 6 خلايا من رموز missing النصية حسب الفحص.

العمود	عدد الناقص	النسبة	تفسير/تعامل مقترح
cause_of_loss	30,367	96.51 %	أولوية منخفضة/عالية حسب هدف التحليل؛ سبب الفاقد غير متاح لمعظم السجلات
notes	29,931	95.12 %	ملاحظات وصفية؛ لا تعوّضيها تلقائيًا
treatment	29,678	94.32 %	تفاصيل المعاملة نادرة جدًا
sample_size	29,603	94.08 %	معلومات حجم العينة متاحة في 1,862 سجلًا فقط
region	29,429	93.53 %	كتير من السجلات على مستوى الدولة أو تجميعات عامة؛ افحصي سياق المصدر
loss_quantity	26,415	83.95 %	الكمية غير موجودة في أغلب السجلات؛ لا تستنتجيها من النسبة من غير إنتاج/مقام مناسب
url	9,342	29.69 %	حوالي 70.31% فقط عندها URL غير فارغ
activity	7,370	23.42 %	قد يؤثر على تحليل النشاط وسلسلة الإمداد
food_supply_stage	3,391	10.78 %	مرحلة سلسلة الإمداد ناقصة في جزء من السجلات
reference	73	0.23 %	نقص قليل لكن مهم لتتبّع المصدر
method_data_collection	36	0.11 %	عدد قليل بدون طريقة جمع بيانات
m49_code, country, cpc_code, commodity, year, loss_percentage, loss_percentage_original	0	0%	لا يوجد نقص مسجل في هذه الأعمدة

قرار التنظيف: ما تملئيش كل القيم الناقصة بكلمة Unknown لمجرد إكمال الجدول. في التحليل الوصفي ممكن نستخدم فئة Missing عند الحاجة، لكن في نمذجة البيانات لازم نقرر حسب معنى العمود والهدف. النقص في cause_of_loss مختلف عن النقص في country أو year؛ لأن الأول ممكن يكون طبيعيًا في بعض الدراسات، بينما الأخير أساسي لتعريف السجل.

4. التكرار، القيم الفريدة، والتوزيعات العامة

اختبار التكرار الكامل أظهر 180 صفًا مكررًا عند استخدام duplicated() بالطريقة الافتراضية، وإجمالي 339 صفًا ينتمي إلى مجموعات تكرار عند keep=False. التقرير النهائي حفظ 339 صفًا في exact_duplicate_rows.csv، وحفظ 2,862 سجلًا مرشحًا للتكرار في duplicate_record_candidates.csv. المرشحون ليسوا بالضرورة تكرارًا حقيقيًا؛ قد يختلفون في السنة أو المرحلة أو المصدر.

ملخص القيم الفريدة أظهر 157 قيمة مختلفة في m49_code، و159 اسمًا في country، و213 اسم سلعة، و196 قيمة cpc_code، و27 سنة، و4,629 قيمة مختلفة في loss_percentage. كل الأعمدة مميزة عن الثابتة؛ مفيش عمود ثابت بالكامل.

• راجعي exact duplicates أولًا مع source/reference/url وباقي الأعمدة قبل الحذف؛ لأن التطابق قد يكون نتيجة دمج مصادر.

• في duplicate candidates، حددي مفتاحًا منطقيًا للسجل حسب تعريف البيانات. ما تستخدميش country+commodity فقط كمفتاح؛ ممكن يكون لنفس السلعة أكتر من سنة أو مرحلة أو دراسة.

• حفظ النسخ الأصلية قبل أي حذف، وسجّلي عدد الصفوف قبل وبعد التنظيف وسبب كل حذف.

5. التحليل الجغرافي: m49_code وcountry وregion

ده جزء حساس لأن قاعدة البيانات ممكن تحتوي دولًا، مناطق جغرافية كبيرة زي World/Africa/Western Africa، وأسماء مناطق محلية مأخوذة من الدراسات. كود M49 صحيح في مرجعه لا يضمن وحده إن اسم البلد المقترن به صحيح.

5.1 عمود m49_code

النتائج: لا توجد قيم ناقصة؛ النوع int64؛ عدد الأكواد الفريدة 157. الاختبار الأول ما أظهرش حالة واحدة لنفس الكود مرتبطة بعدة أسماء داخل فحص محدد، لكن اختبار التوافق الرسمي اسم+كود كشف حالات تحتاج مراجعة. كمان تم توحيد شكل الكود في نسخة المقارنة بإضافة أصفار بادئة عند الحاجة، مثل 1 إلى 001، من غير تغيير العمود الأصلي.

5.2 عمود country

النتائج: لا توجد أسماء ناقصة؛ عدد الأسماء الفريدة 159؛ 17 اسمًا اتعلموا كحالات capitalization أو تسمية غير قياسية. لا توجد مسافات زائدة في بداية/نهاية الاسم ولا مسافات داخلية متكررة. الفحص وجد 14 قيمة في country تبدو كأسماء مناطق جغرافية أو تجميعات، مثل World وAfrica وWestern Africa وAsia وEurope وLatin America and the Caribbean. لذلك مش كل قيمة في country تمثل دولة مستقلة بالمعنى المعتاد.

5.3 مطابقة الدولة مع M49

النتائج المسجلة: 30,735 سجلًا في حالة PASS، و730 سجلًا باسم غير موجود حرفيًا في قائمة أسماء UN M49 المستخدمة. جدول مشاكل المطابقة النهائي يحتوي 282 صفًا يحتاج مراجعة. الفرق بين 730 و282 ناتج عن اختلاف عدّ السجلات/الحالات في جداول الفحص المختلفة، فلازم نراجع تعريف كل جدول قبل دمج الأعداد. أمثلة أسماء محتاجة توحيد أو تحقق: World، أسماء أقاليم مجمعة، China,Taiwan، United Kingdom، The former Yugoslav Republic of Macedonia، Turkey، Palestine، Côte d'Ivoire، وغيرها.

التوصية: لا نعدّلش الاسم أو الكود تلقائيًا. اعملي mapping table واضح فيه original_m49_code، original_country، evidence/source، decision، suggested_code، suggested_official_name. الأسماء الإقليمية مثل World أو Africa لازم يكون لها نوع سجل مختلف عن country_or_area عشان ما تتعاملش كأنها دولة عادية.

5.4 عمود region

النتائج: 29,429 قيمة ناقصة (93.53%)، و2,036 قيمة موجودة. هناك دول عندها عدد كبير من أسماء المناطق المختلفة؛ من أمثلة الملخص: الهند 43 تسمية، الصين 38، بنغلاديش 32، إثيوبيا 23، غانا 34، ومصر 11. هذا لا يثبت وجود أخطاء؛ قد تكون أسماء محافظات أو مناطق دراسة.

المرجع الجغرافي الرسمي الذي جرى بناؤه يحتوي 1 مستوى عالمي، و5 مناطق رئيسية، و17 منطقة فرعية، و7 مناطق وسيطة. ظهر 377 اسم منطقة ملاحظًا خارج تسميات UN M49 الهرمية، وملف المراجعة النهائي يحوي 378 تسمية/صفًا؛ والفرق مرتبط بطريقة تجميع النتائج. كما ظهر 666 سجلًا يحتاج مراجعة مستوى المنطقة. أمثلة أسماء محلية: Uttarakhand، Comilla، Western Cape Province، Rangpur and Dinazpur district.

المناطق المشتركة بين دول مختلفة ظهرت مثل Punjab في بنغلاديش والهند وباكستان، وAssam في الهند وبيرو، وNational average في مصر والأردن. الاسم نفسه لا يعني بالضرورة نفس المكان؛ لازم نربطه بالدولة ونوع المنطقة.

قرار العمل: صنّفي region إلى aggregate / national_average / ecological_zone / district / province / local_region / unknown بعد مراجعة المصدر. ما تحذفيش region لمجرد إنه مش موجود في M49؛ M49 مش قاموسًا شاملًا لكل منطقة محلية في الدراسات.

6. تحليل cpc_code وربطه بالسلعة commodity

العمود cpc_code فيه صفر missing من أصل 31,465، وعدد القيم الفريدة 196. تم تحميل مرجع CPC 2.1 الرسمي من ملف Excel حسب مخرجات الـ Notebook، مع مقارنة الأكواد وعناوينها. لازم ننتبه إن CPC تصنيف للمنتجات، ومش هو نفسه HS؛ فلازم ما نقارنش الأكواد بين التصنيفين كأنهما نفس النظام.

النتائج التفصيلية

- لا توجد أكواد ناقصة ولا مسافات/قيم فارغة ظاهرة في اختبار التنسيق.
- ظهر 7 سجلات بأكواد تحتوي أحرفًا أو خارج النمط الأولي المتوقع؛ الأمثلة الظاهرة 21116i و2351f. لا تفترضي إنها غلط نهائيًا قبل الرجوع لنسخة CPC المعتمدة، لكن لازم تتراجع لأنها لا تتبع النمط الرقمي المعتاد.
- هناك 30,719 سجلًا كودها يبدأ بصفر؛ وده طبيعي في تصنيفات الأكواد، لذلك لازم تخزين cpc_code كنص وعدم تحويله إلى رقم حتى لا تضيع الأصفار البادئة.
- فحص التهجئة والتنسيق لنفس الكود لم يُظهر اختلافات نصية في خطوة محددة، لكن فحص many-to-many كشف أكوادًا مرتبطة بأكثر من اسم سلعة أو أسماء قريبة؛ لذلك تم إنشاء مراجعة أكواد CPC فيها 196 صفًا.
- أمثلة الأكواد/السلع التي ظهرت في جداول المراجعة: 01199.90 مع Cereals n.e.c. وOther cereals n.e.، و01353.01 مع Raspberries وRaspeberries. قد تكون أسماء مترادفة أو اختلافات مصدر أو مشكلة mapping.

الإجراء المقترح: اعملي جدول crosswalk بين cpc_code الأصلي، عنوان CPC الرسمي، commodity المسجل، نتيجة المطابقة، وقرار المراجع. الأكواد التي لا تطابق المرجع تُعلَّم للمراجعة، ولا يُستبدل اسم السلعة بالعنوان الرسمي تلقائيًا قبل التأكد من إصدار CPC ومن مستوى التفصيل.

7. تحليل commodity — أسماء السلع

النتائج: لا توجد قيم ناقصة، وعدد أسماء السلع الفريدة 213. فحص اختلاف الحروف/المسافات اكتشف حالتين أساسيتين لاختلاف شكل الكتابة: Cheese from Whole Cow Milk مقابل Cheese from whole cow milk، وRice, Milled مقابل Rice, milled. فحص singular/plural لم يعرض اختلافات إضافية في الجدول الناتج.

ظهر 28 اسم سلعة نادر الاستخدام، و669 سجلًا لسلع ممكن تكون فئات عامة بدل منتج محدد، مثل Cereals n.e.c. وMixed grain. كلمة n.e.c. معناها عادةً «غير مصنف في موضع آخر» ضمن التصنيف، وليست خطأ تلقائيًا.

- اعملي نسخة normalized للمقارنة (lowercase/trim)، لكن احتفظي بالاسم الأصلي.
- راجعي أسماء السلع النادرة مع CPC؛ ممكن تكون سليمة لكنها قليلة الظهور.
- حددي هل التحليل محتاج فئات عامة؛ لو آه، خليه مستوى تصنيف مستقل بدل حذفها.

8. تحليل year — السنة

النتائج: لا توجد قيم ناقصة أو غير رقمية. نطاق السنوات 2000–2026، وعدد السنوات المختلفة 27. لم تظهر سنوات خارج نطاق المراجعة 1965–2026، ولا سنوات مستقبلية، ولا سنوات قديمة جدًا حسب القواعد الموجودة في الخلايا.

الاستنتاج: لا توجد مشكلة واضحة في تنسيق عمود السنة في الـ outputs المحفوظة. لكن لازم نتأكد من دلالة 2026 في المصدر: سنة نشر/تحديث أم سنة بيانات فعلية؛ وجودها لا يعني وحده إن القيمة غلط.

9. تحليل loss_percentage — نسبة الفاقد

العمود رقمي float64، وعدد القيم الناقصة صفر. أقل قيمة 0، وأعلى قيمة 65، والمتوسط 4.683، والوسيط 2.65، والانحراف المعياري 6.359 تقريبًا. عدد القيم الفريدة 4,629.

فحص المجال 0–100 لم يجد أي سجل خارج النطاق. لكن طريقة IQR اعتبرت 3,555 قيمة outlier (حوالي 11.3%)؛ الحد الأعلى الإحصائي كان نحو 9.1275. ده مش معناه إن النسب فوق 9.13% غلط، لأن توزيع الفاقد ممكن يكون منحرفًا ووجود نسب كبيرة ممكن يكون حقيقيًا حسب السلعة والدراسة.

هناك 3,191 قيمة موجبة بين 0 و1، وده يستحق مراجعة وحدة القياس: هل القيمة 0.5 تعني 0.5% أم نسبة عشرية تمثل 50%؟ لا نقدر نقرر من القيمة وحدها. فحص factor-of-100 لم يجد أي اختلاف محتمل في القيم القابلة للمقارنة.

مقارنة loss_percentage مع loss_percentage_original

النتائج: 22,025 سجلًا أمكن تحويل قيمته الأصلية إلى رقم ومقارنتها بالقيمة الحالية؛ لم يوجد أي mismatch في المقارنة الرقمية ولم تظهر فروق محتملة بعامل 100. لكن 9,440 قيمة في العمود الأصلي لم تتحول مباشرة لرقم، و9,025 قيمة تحتوي علامة %، ولا توجد قيم تحتوي فاصلة comma حسب الاختبار. هذا متوقع جزئيًا لأن العمود الأصلي يحافظ على النص كما ورد، وقد يحتوي نطاقات مثل 0–3% أو نصوصًا مختلطة.

قرار العمل: اعتبري loss_percentage هو الحقل الرقمي الحالي، واحتفظي بـ loss_percentage_original لأغراض التدقيق. القيم المتطرفة تُراجع مع المرجع والسلعة والسنة، ولا تُقصّ أو تُحذف تلقائيًا.

10. تحليل loss_quantity — كمية الفاقد

النتائج: 26,415 قيمة ناقصة (83.95%)؛ بقيت 5,050 قيمة غير فارغة، لكن 691 منها لا تتحول إلى رقم مباشرة. أمثلة نصية: 60 million metric tons، و44.09kgs، وغيرها من القيم التي تتضمن وحدة أو وصفًا.

بعد التحويل الرقمي، عدد القيم القابلة للتحليل في الملخص 4,359. المتوسط 64,356.68، والوسيط 7,000، والحد الأدنى 0، والحد الأقصى 3,824,000. الربع الأول 1,022 والربع الثالث 36,000، والحد الأعلى الإحصائي بطريقة IQR يساوي 88,467؛ ظهرت 601 قيمة كمرشحات extreme.

لم تظهر كميات سالبة، وظهر 56 سجلًا بقيمة صفر. الصفر ليس خطأ تلقائيًا؛ ممكن يعني عدم وجود فاقد أو نتيجة مُبلّغ عنها بصفر، لكن لازم مراجعة المصدر.

- أنشئي loss_quantity_raw للاحتفاظ بالنص الأصلي.
- أنشئي loss_quantity_numeric منفصلًا، مع quantity_unit منفصلًا مثل kg أو metric ton أو million metric tons.
- حوّلي الوحدات فقط لما تكون الوحدة صريحة ومفهومة. لا تضربي أو تقسمي القيم بشكل تخميني.
- راجعي الـ 601 قيمة الكبيرة مع السلعة والدولة والسنة والمصدر، لأن IQR لا يعرف وحدات القياس.

11. تحليل sample_size — حجم العينة

النتائج: 29,603 قيمة ناقصة (94.08%)، و1,206 قيمة غير رقمية. بعد التحويل، عدد القيم الرقمية الملخصة 656؛ المتوسط 308.35، والوسيط 100، وأقصى قيمة 988. فحص القيم السالبة والصفرية لم يعثر على أي حالة.

ظهر سجلان بقيمة عشرية 1.193 في أوغندا لعام 2016، مرتبطان بـ Maize (corn) وFlour of triticale. لأن حجم العينة غالبًا عدد وحدات/عينات، القيمة العشرية تحتاج الرجوع لتعريف المصدر: ربما وزن/معامل أو قيمة في عمود ليس sample count فعليًا.

لم يكتشف IQR أي outliers ضمن القيم الرقمية القابلة للتحليل، لكن ده لا يثبت إن كل القيم منطقية؛ الاختبار الإحصائي لا يعرف تعريف sample_size.

12. تحليل activity — النشاط

النتائج: 7,370 قيمة ناقصة (23.42%)، و180 تسمية نشاط فريدة. اختبار المسافات/اختلاف الحروف لم يجد اختلافات تنسيق مباشرة، لكن فحص التشابه النصي وجد 60 زوجًا متشابهًا يحتاج مراجعة. وُصفت 98 تسمية بأنها نادرة، بينما لم يعثر النمط المستخدم على سجلات broad activity. كما ظهرت 1,503 تركيبة مختلفة بين النشاط والسلعة.

من أمثلة الأنشطة الشائعة Storage بعدد 6,072، وTransportation بعدد 5,290. وجود نشاط نادر لا يعني خطأ؛ بعض الدراسات تستخدم وصفًا طويلًا لعدة عمليات معًا.

التعامل: لا تدمجي الأنشطة المتشابهة آليًا. راجعي الأزواج المتشابهة، وحددي هل النشاط مفرد أم سلسلة عمليات، وبعدها ضعي قاموسًا معياريًا يحتفظ بالنص الأصلي.

13. تحليل food_supply_stage — مرحلة سلسلة الإمداد

النتائج: 3,391 قيمة ناقصة (10.78%)، و20 مرحلة فريدة. لم يظهر اختلاف تنسيق مباشر أو أزواج أسماء متشابهة حسب الاختبارات. لكن 6,147 سجلًا وُسمت كمرشحة لمرحلة عامة لأن القيمة Whole supply chain واسعة وتشمل السلسلة كلها.

ظهرت 286 تركيبة مختلفة بين المرحلة والنشاط. ومن الأمثلة أن Farm لها 10,103 سجلًا و73 نشاطًا فريدًا، وWhole supply chain لها 6,147 سجلًا و42 نشاطًا فريدًا، وStorage لها 3,216 سجلًا. هذه التركيبات تحتاج فهم المجال، مش شرط تكون أخطاء.

التعامل: احتفظي بـ Whole supply chain كفئة aggregate منفصلة عن المراحل المحددة مثل Harvest أو Storage أو Retail، ولا تقارنيها كأنها مرحلة مفردة.

14. تحليل treatment — المعاملة أو طريقة التعامل

النتائج: 29,678 قيمة ناقصة (94.32%)، و764 قيمة غير فارغة/فريدة بحسب ملخص القيم الفريدة (مع اختلاف احتساب missing). قائمة التكرارات تُظهر إن NaN هو الأكثر ظهورًا، وبعده أمثلة مثل Boro rice وAman rice. فحص التشابه النصي أعاد 1,459 زوجًا/سطرًا للمراجعة، وهو رقم كبير يدل على إن النصوص قد تحتوي وصفًا تفصيليًا طويلًا وليس مجرد تصنيفات قصيرة.

الفحص أظهر أمثلة عامة مثل Other storage methods وUnspecified storage، وراجع توافق treatment مع activity وfood_supply_stage. ظهر تحذير Python من regular expression يحتوي مجموعات؛ التحذير لا يعني أن النتيجة خاطئة تلقائيًا، لكنه يستحق تعديل التعبير أو استخدام non-capturing groups مثل (?:...) لتقليل التحذير.

التعامل: ما تعمليش deduplication على treatment بالاعتماد على التشابه النصي فقط. افصلي بين نوع المعاملة، اسم الصنف/الموسم، وظروف التجربة/التخزين إذا كان المصدر يسمح، مع حفظ الوصف الأصلي.

15. تحليل cause_of_loss — سبب الفاقد

النتائج: 30,367 قيمة ناقصة (96.51%)، و1,098 سجلًا فقط بها قيمة سبب غير فارغة. ظهر 406 اسم/قيمة سبب غير فارغة (407 عند احتساب missing). من أكثر القيم المسجلة Physical Losses بعدد 87، وInsect pest damage بعدد 54، وMechanical Damage بعدد 36.

ظهر 453 سجلًا مرشحًا لاحتواء أكثر من سبب داخل خلية واحدة. تحليل مستوى التفصيل أظهر أن أطوال الوصف متفاوتة جدًا: متوسط عدد الحروف نحو 77.12، والحد الأدنى 4، والحد الأقصى 2,594 حرفًا. بعض القيم جملة كاملة أو وصف نتائج دراسة، مش اسم سبب قصير.

تم فحص احتمال خلط السبب بالنتيجة أو وصف الفاقد نفسه، ومراجعة الأسباب حسب commodity/activity/stage. فحص النص الآلي مجرد مؤشر؛ الحكم يحتاج قراءة السجل ومصدره.

التعامل: لو هدفك تحليل أسباب الفاقد، اعملي cause_raw وcause_category. قسّمي القيم متعددة الأسباب إلى صفوف منفصلة فقط بعد تحديد delimiter ومعنى النص، واحتفظي بربط كل قيمة بالسجل الأصلي. لا تحوّلي وصفًا كاملًا لفئة واحدة بالتخمين.

16. تحليل method_data_collection — طريقة جمع البيانات

النتائج: 36 قيمة ناقصة (0.11%)، و11 طريقة معروفة بالإضافة إلى missing. التوزيع المسجل: Modelled Estimates = 19,497؛ FAO's annual Agriculture Production Questionnaires = 4,209؛ Survey = 3,220؛ Literature Review = 1,694؛ National Accounts = 1,275؛ Controlled Experiment = 629؛ Case Study = 528؛ No Data Collection Specified = 207؛ Expert Opinion = 128؛ FLW Protocol = 41؛ Census = 1.

فحص اختلافات التنسيق لم يجد نتائج، وفحص الأسماء المتشابهة لم يجد أزواجًا. لكن الخلية الخاصة بالتمييز بين طريقة جمع البيانات وطريقة تقدير الفاقد عرضت تحذيرًا من regex وأظهرت سجلات كثيرة تحتاج تفسيرًا. لازم نميّز بين Survey مثلًا، وModelled Estimates، وNational Accounts؛ دي مش طرق متطابقة من حيث الثقة أو المعنى.

17. تحليل reference وurl وnotes

reference: 73 قيمة ناقصة (0.23%). تم العثور على حالتين لتنوعات في تنسيق المرجع بعد التطبيع؛ واحدة لها 25 سجلًا، والثانية 58 سجلًا. ده غالبًا اختلاف في capitalization/صياغة اسم المرجع، لكن لازم ما ندمجش مراجع مختلفة لمجرد تشابه النص.

url: 9,342 قيمة ناقصة (29.69%). جرى إخراج جدول URL validation review وجداول الروابط المكررة. المخرجات المتاحة ما بتديش هنا رقمًا واحدًا موثوقًا لعدد الروابط غير الصالحة؛ لذلك لازم مراجعة جدول URL validation review نفسه بدل افتراض أن كل URL موجود سليم.

notes: 29,931 قيمة ناقصة (95.12%). فحص الترميز لم يعرض صفوفًا في جدول مشاكل الترميز. تم أيضًا البحث عن ملاحظات قد تحتوي معلومات منظمة/تفاصيل إضافية؛ وجود ملاحظات طويلة لا يعني تلقائيًا أنها خطأ، لكن ممكن تكون محتاجة استخراج حقول منفصلة إذا كانت ذات قيمة للتحليل.

فحص التكرار داخل reference وurl وnotes أظهر صفوفًا متكررة، لكن التكرار في رابط أو مرجع وحده مش دليل إن السجلات مكررة؛ المصدر الواحد ممكن يدعم عدة سلع أو سنوات أو مراحل.

نقطة مهمة في تتبع المصدر

الأفضل لكل سجل نحتفظ بـ reference_original وurl_original، ونضيف حقول فحص مثل reference_status وurl_status وsource_verified_on. لو رابط ناقص لكن المرجع موجود، نبحث عن الرابط من مصدر موثوق ونضيفه كحقل جديد مع توثيق مصدر الإضافة، بدل ما نغيّر النص الأصلي.

18. ملفات التقارير التي حفظتها خلية التدقيق النهائي

مخرجات خلية التدقيق النهائي في الـ Notebook بتقول إن التقارير التالية اتحفظت تحت report/step_1_validation في بيئة التشغيل المسجلة. المسار الظاهر في الـ output هو مسار Windows من الجهاز اللي اتنفذ عليه الـ Notebook، وليس ضمانًا إن نفس المسار موجود عندك.

اسم الملف	الحجم في الـ output	بيستخدم في إيه؟
column_profile.csv	18 صفًا	ملخص الأعمدة
exact_duplicate_rows.csv	339 صفًا	كل الصفوف التي تنتمي لتكرارات مطابقة
duplicate_record_candidates.csv	2,862 صفًا	سجلات مرشحة للتكرار وليست مكررة مؤكدة
geographic_validation_status_summary.csv	4 صفوف	ملخص حالات التحقق الجغرافي
country_code_issues.csv	282 صفًا	مراجعة أزواج اسم الدولة وكود M49
region_level_review.csv	666 صفًا	مراجعة مستوى/نوع المنطقة
unexpected_region_report.csv	378 صفًا	تسميات مناطق خارج قائمة M49 الهرمية
cpc_code_review.csv	196 صفًا	مراجعة كود CPC وعلاقته بالسلعة
reference_format_review.csv	2 صف	اختلافات تنسيق في المراجع
out_of_range_loss_percentage.csv	0 صف	لا توجد نسب خارج 0–100 في الفحص
negative_loss_quantity.csv	0 صف	لا توجد كميات سالبة
invalid_sample_size.csv	1,206 صفًا	قيم sample_size غير القابلة للتحويل لرقم
run_manifest.json	ملف JSON	ملخص التشغيل والمصدر وبعض الإحصاءات

الملخص النهائي المسجل: Rows = 31,465، Columns = 18، Exact duplicate rows including all copies = 339، Rows with at least one missing value = 31,465، Rows with no missing values = 0.

19. خطة التعامل مع المشاكل — بالترتيب المقترح

- أولًا — تثبيت المصدر: احفظي نسخة raw غير قابلة للتعديل، وسجّلي اسم الملف وتاريخ التحميل وحجمه وبصمة hash لو متاح.
- ثانيًا — التكرار: افحصي الـ 339 تكرارًا كاملًا، ثم راجعي الـ 2,862 مرشحًا للتكرار. ما تحذفيش أي صف قبل تحديد مفتاح السجل وسبب التكرار.
- ثالثًا — جغرافيا M49: راجعي 282 حالة country-code، وصنّفي الأسماء إلى دولة/منطقة تجميعية/اسم بديل/اسم محلي. راجعي الـ 666 حالة region-level منفصلة.
- رابعًا — CPC: راجعي 196 حالة، وخصوصًا الأكواد السبعة ذات الحروف. تحققي من إصدار CPC الرسمي ومن أن العمود محفوظ كنص.
- خامسًا — الوحدات: حللي 691 قيمة loss_quantity غير رقمية و601 قيمة كمية متطرفة، وافصلي الوحدة عن القيمة قبل أي تحويل.
- سادسًا — النسبة: راجعي 3,555 outlier و3,191 قيمة بين 0 و1 في ضوء المصدر والوحدة، من غير حذف أو تصحيح تلقائي.
- سابعًا — sample_size: افهمي 1,206 قيمة غير رقمية، والسجلين ذوي القيمة 1.193. تحققي هل العمود يمثل عددًا أم قيمة وصفية أخرى.

• ثامنًا — التصنيفات النصية: راجعي 60 زوج نشاط متشابه، و98 نشاطًا نادرًا، و6,147 سجل Whole supply chain، و1,459 مرشحًا لتشابه treatment، و453 سجلًا متعدد الأسباب.

• تاسعًا — المصادر: راجعي 73 مرجعًا ناقصًا و9,342 URL ناقصًا و29,931 notes ناقصة. فرّقي بين النقص الطبيعي ونقص التوثيق الذي يمنع التحقق.

• عاشرًا — سجل القرارات: لكل تغيير، خزّني original_value وcleaned_value وrule_applied وreview_status وevidence/source؛ وخلي قرارات التصحيح قابلة لإعادة التنفيذ.

20. حدود التقرير وما الذي لا ينبغي استنتاجه

- الـ outlier الإحصائي مش خطأ مؤكد؛ هو قيمة بعيدة عن توزيع البيانات حسب قاعدة محددة.
- قيمة مفقودة في treatment أو cause_of_loss قد تكون طبيعية لو الدراسة لم تسجل هذا التفصيل، لكنها تقلل صلاحية بعض التحليلات.
- اسم منطقة خارج M49 لا يعني أنه اسم غير صحيح؛ M49 مرجع للتقسيمات الجغرافية الواسعة وليس قائمة بكل القرى والمحافظات ومناطق الدراسات.
- اسم دولة لا يظهر في UN M49 قد يكون اسمًا تاريخيًا أو بديلًا أو تجميعة جغرافية؛ لازم تصنيف نوع السجل قبل الحكم.
- وجود رقم في loss_quantity لا يعني أن كل القيم بنفس الوحدة؛ النصوص مثل kg أو million metric tons تحتاج تحويلًا موثقًا.
- نتائج الـ Notebook محفوظة في الملف المرفوع، لكن التقرير لا يدّعي أنه أعاد تشغيل الخلايا أو اختبر كل الروابط الخارجية في وقت إعداد الـ PDF.
- بعض الخلايا أظهرت Python UserWarning بسبب regular expressions. دي تحذيرات وليست أخطاء تنفيذ بالضرورة، لكن الأفضل مراجعتها وتنظيف الـ patterns.

21. المراجع المستخدمة أو المشار إليها في الـ Notebook

الروابط التالية مأخوذة من سجل الروابط والتوثيق الموجود في الـ Notebook، وتُستخدم لفهم قاعدة البيانات والتحقق من الأكواد. الوصول الحالي لكل رابط لم يُختبر أثناء إنشاء التقرير.

- FAO Food Loss and Waste Database: https://www.fao.org/platform-food-loss-waste/flw-data/en/
- FAO FLW User Guide: https://www.fao.org/platform-food-loss-waste/flw-data/user-guide/en
- UN M49 Overview: https://unstats.un.org/unsd/methodology/m49/overview/
- UN M49 Methodology: https://unstats.un.org/unsd/methodology/m49/
- CPC Version 2.1 explanatory notes file: https://unstats.un.org/unsd/classifications/Econ/Download In%20Text/CPC_Ver_2.1_Exp_Notes_Updated_3Apr2025.xlsx/

الخلاصة النهائية

الداتا قابلة للتحليل، لكن قبل استخدامها في Dashboard أو Machine Learning، لازم نحدد هدف التحليل ونراجع الجغرافيا والتكرار والوحدات. الأولوية ليست ملء كل الخانات؛ الأولوية هي معرفة أي القيم موثوقة، وأيها ناقصة طبيعيًا، وأيها تحتاج توحيدًا أو مراجعة من المصدر. احتفظي بالأصل، وأنشئي أعمدة نظيفة منفصلة، ووثّقي كل قرار.